

隐马尔可夫模型（**Hidden Markov Model**，**HMM**）是可以用于标注问题的统计学模型，描述由隐藏的马尔可夫链随机生成观测序列的过程，属于生成模型。在语音识别、自然语言处理、生物信息、模式识别等领域有着广泛的应用。

1 隐马尔可夫模型的基本概念

1.1 隐马尔可夫模型的定义

隐马尔可夫模型是关于时序的概率模型，描述了一个隐藏的马尔可夫链生成不可观测的状态随机序列，再由各个状态生成对应观测的过程。

定义相关符号

- 设 \mathbf{Q} 是所有的状态集合， $\mathbf{Q} = q_1, q_2, \dots, q_N$ ， N 是可能的状态数
- 设 \mathbf{V} 是所有的观测集合， $\mathbf{V} = v_1, v_2, \dots, v_M$ ， M 是可能的观测数
- \mathbf{I} 是长度为 T 的状态序列， $\mathbf{I} = i_1, i_2, \dots, i_T$
- \mathbf{O} 是长度为 T 的观测序列， $\mathbf{O} = o_1, o_2, \dots, o_T$

隐马尔可夫模型主要由三部分组成

- 初始状态概率分布 $\pi(R^N)$
- 状态转移概率矩阵 $\mathbf{A}(R^N \times R^N)$
- 观测生成概率矩阵 $\mathbf{B}(R^N \times R^M)$

隐马尔可夫模型作了两个基本假设

- 齐次马尔可夫性假设（状态）：假设任意 t 时刻的状态只依赖于前一时刻 $t-1$ 的状态
- 观测独立性假设（序列）：假设任意 t 时刻的观测只依赖于 t 时刻的状态

隐马尔可夫模型可以用于标注问题，这时状态对应着标记。标注问题是给定观测序列去预测对应的状态序列（标记序列），可以假设标注问题的数据是由隐马尔可夫模型生成的，这样我们可以利用隐马尔可夫模型的学习与预测算法进行序列标注。

1.2 隐马尔可夫的生成过程

输入： \mathbf{A} ， \mathbf{B} ， π ，观测序列长度 T

输出：观测序列

Step1: 令 $t = 1$

Step2: 按照初始状态概率分布 π 随机生成状态 i_t

Step3: 根据观测概率矩阵 B 生成 t 时刻的观测 o_t

Step4: 根据状态概率转移矩阵 A 生成 $t + 1$ 时刻的状态 i_{t+1}

Step5: 令 $t = t + 1$ ，如果 $t < T$ ，转到**Step3**，否则终止

1.3 隐马尔可夫的3个基本研究问题

- 概率计算问题（模型定义），即给定模型的参数 $\lambda = (A, B, \pi)$ ，计算 $P(O|\lambda)$ 的概率
- 学习问题（模型参数求解，训练），给定观测 O ，估计模型参数 $\lambda = (A, B, \pi)$ ，通过极大似然估计求解模型参数，即最大化 $P(O|\lambda)$ 进行求解
- 预测问题（预测），序列标注问题上也称解码问题，给定模型参数 $\lambda = (A, B, \pi)$ 和观测序列 O ，求最大 $P(I|O, \lambda)$ 对应的状态序列

2 概率计算方法

2.1 直接计算法

为了计算 $P(O|\lambda)$ ，枚举所有长度可能为 T 的状态序列，一共有 N^T 这么多条状态序列，其中任意一条状态序列 I 的长度为 T ，对所有的状态序列进行求和（相当于对联合概率 $P(O, I|\lambda)$ 进行积分，求边缘概率），即 $\sum_I P(O|I, \lambda)P(I|\lambda)$ 时间复杂度为 $O(N^T * T)$ ，不可行，需要引入前向或后向算法

2.2 前向算法

定义前向概率

给定模型参数 λ ，定义从开头到 t 时刻的观测序列为 o_1, o_2, \dots, o_t 且 t 时刻状态为 q_i 的概率为前向概率，记作 $\alpha_t(i) = P(o_1, o_2, \dots, o_t, i_t = q_i | \lambda)$

接下来可以递推地求得前向概率 $\alpha_t(i)$ 以及观测序列概率 $P(O|\lambda)$


输入：隐马尔可夫模型参数 λ ，观测序列 O

输出：观测序列概率 $P(O|\lambda)$

Step1: 初始化， $\alpha_1(i) = \pi_i b_i(o_1)$ （ $t = 1$ 时刻，状态为 q_i 且由 q_i 状态生成 o_1 观测的概率）

Step2: 递推， $\alpha_{t+1}(i) = [\sum_{j=1}^N \alpha_t(j) a_{ji}] b_i(o_{t+1})$ ，请见下图


Step3: $P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$ （ T 时刻的状态有 N 种可能，对这 N 种可能进行求和， $\alpha_T(i) = P(o_1, o_2, \dots, o_T, i_T = q_i | \lambda)$ ，求和之后就是 $P(o_1, o_2, \dots, o_T | \lambda)$ ）



下面分析下它的复杂度

前向算法高效的关键是其局部计算前向概率，然后利用路径结构将前向概率“推算”全局，得到 $P(O|\lambda)$

具体地，在时刻 $t = 1, 2, \dots, T - 1$ ，计算 $\alpha_{t+1}(i)$ 的 N 个值 ($i = 1, 2, \dots, N$)，而每个 $\alpha_{t+1}(i)$ 的计算利用到前一时刻的 N 个 $\alpha_t(j)$ ，减少计算量的原因在于每一次计算直接引入前一个时刻的计算结果，避免重复计算（如下图，如果要计算 T 时刻 q_i 的概率的话，左边有 N^{T-1} 这么多条路径可以到达 q_i ，是指数级增长的），前向算法复杂度为 $O(N^2 * T)$ (t 时刻的 q_i 需要利用 $t-1$ 时刻的 N 个状态， t 时刻一共需要计算 N 个 q_i ，一共有 T 个时刻)



2.3 后向算法

与前向相反，不再具体阐述

3 学习算法

这里主要介绍有标记的序列，即有监督学习的方法

假设所有训练样本的长度都相同，训练样本： $\{(O_1, I_1), (O_2, I_2), \dots, (O_S, I_S)\}$

通过极大似然函数进行估计，也就是统计样本中以下三个参数


- 状态转移概率 a_{ij} ，统计状态 i 转移到状态 j 的样本数量，归一化
- 观测生成概率 $b_j(k)$ ，统计状态 j 且观测为 k 的数量，归一化
- 初始状态概率 π_i ，统计第一个状态是 i 的数量，归一化

4 预测算法

解决隐马尔可夫模型的预测问题常用维特比算法(Viterbi)，即用动态规划求概率最大的路径，这条概率最大的路径对应着一个状态序列。维特比算法的大致思想就是，通过前向概率计算 t 时刻，每个状态 i 的最大概率，并且记录使得状态 i 取最大时的前驱状态 j ，从 $t=1$ 开始计算，在 T 时刻，选取一个概率最大的状态 i^* ，通过前驱一直回溯，从而得到最优状态序列。下面引入两个关键变量 δ 和 ψ

- 定义在 t 时刻以状态 i 为终点的最大概率为 $\delta_t(i) = \max_j [\delta_{t-1}(j)a_{ji}]b_i(o_t)$
- 定义使得 t 时刻以状态 i 为终点的最大概率的前一个状态 $\psi_t(i) = \operatorname{argmax}_j [\delta_{t-1}(j)a_{ji}]$

如下图所示， $\delta_3(2) = 0.01008$ 的意思是，在第3个时刻以状态2为终点的最大概率（在第3个时刻，到达状态2这个结点的路径有很多，我们需要的是最大的那条，图中只画出了最大的，即 $0.28 \rightarrow 0.0504 \rightarrow 0.01008$ ）， $\psi_3(2) = 2$ 的意思是，这个最大概率发生时的前一个状态是2



参考资料

1. 《统计学习方法》第10章 隐马尔可夫模型